PRODUKTION OG TESTNING AF PDF-DOWNLOADER

Af Thomas Dyrholm Siemsen

DAGSORDEN

Produktion af egen:

- Forberedelse
- Kode eksempel
- Resultat og læring

Test af Lunas script

4 steps. 4 kerne funktioner:

FORBEREDELSE

4 steps. 4 kerne funktioner:

1. List handling

FORBEREDELSE

4 steps. 4 kerne funktioner:

1. List handling
2. Create folder

FORBEREDELSE

4 steps. 4 kerne funktioner:

1. List handling
2. Create folder
3. Download files

FORBEREDELSE

4 steps. 4 kerne funktioner:

1. List handling
2. Create folder
3. Download files
4. Create report

FORBEREDELSE

FORBEREDELSE

4 steps. 4 kerne funktioner:

1. List handling
2. Create folder
3. Download files
4. Create report

Use case: Ideal User Interaction

FORBEREDELSE

4 steps. 4 kerne funktioner:

1. List handling
2. Create folder
3. Download files
4. Create report

Use case: Ideal User Interaction

Bøvlede med at installere python packages.

KODE

```
import os
import pandas
import requests
import csv
import datetime

#   ---
#
#   Hello user
#
#   ...
#
#   ---


inputFiles = pandas.read_excel("GRI_2017_2020 (1).xlsx")
pdf_files = []
folderNr = 1
downloadedNr = 0
notDownloadedNr = 0
rowsProcesedNr = 0
```

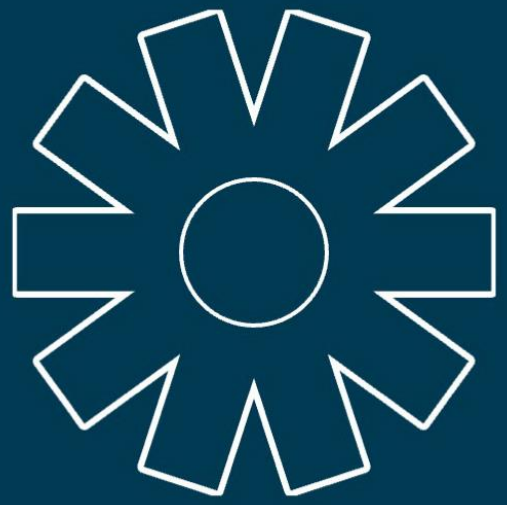

Det første

KODE

```python
def downloadAllPDFS():
    global pdf_files
    global downloadedNr
    global notDownloadedNr
    for item in pdf_files:
        downloadOnePdf(item, 1)
    print("\nDone with downloading...")
```

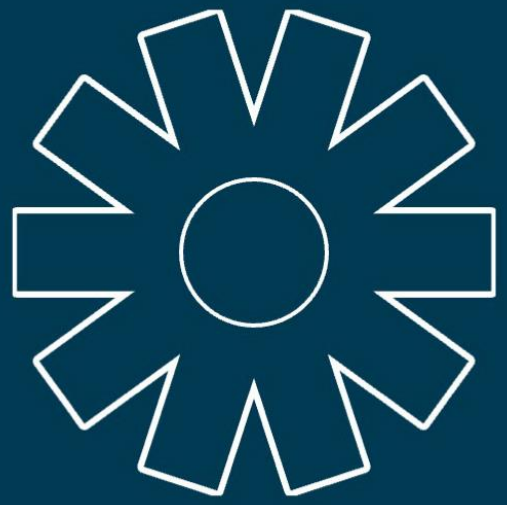

downloadAllPDFS()

KODE

```python
def downloadAllPDFS():
    global pdf_files
    global downloadedNr
    global notDownloadedNr
    for item in pdf_files:
        downloadOnePdf(item, 1)
    print("\nDone with downloading...")



def downloadOnePdf(item, attempt):
    global downloadedNr
    global notDownloadedNr
    global folderNr
    global rowsProcesedNr
    error = 0

    link = item[2] if attempt == 1 else link = item[3]

    _, file_extension = os.path.splitext(str(link))
```

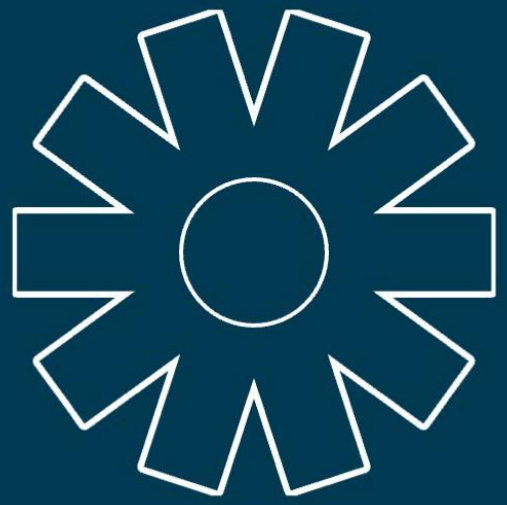

downloadAllPDFS()
downloadOnePdf()

KODE

```
try:
    r = requests.get(link,timeout=3)
    r.raise_for_status()

    file_Path = 'Downloaded pdfs'+str(folderNr)+'/'+item[1]+'.pdf'

    if file_extension == ".pdf":
        if r.status_code == 200:
            with open(file_Path, 'wb') as file:
                file.write(r.content)
            item[0] = "yes"
            downloadedNr += 1
            rowsProcesedNr += 1
    else:
        error = 1

except requests.exceptions.RequestException as err:
    #print ("File "+item[1]+" error: ",err)
    error = 1
```

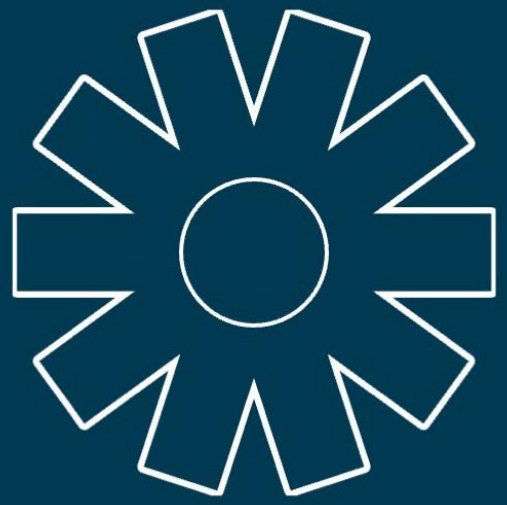

downloadOnePdf()
try, except

KODE

```
if error == 1:
    if attempt == 1:
        downloadOnePdf(item, 2)
    if attempt == 2:
        item[0] = "no"
        notDownloadedNr += 1
        rowsProcesedNr += 1

if rowsProcesedNr % 1000 == 0:
    print('\n Status: ...')
```

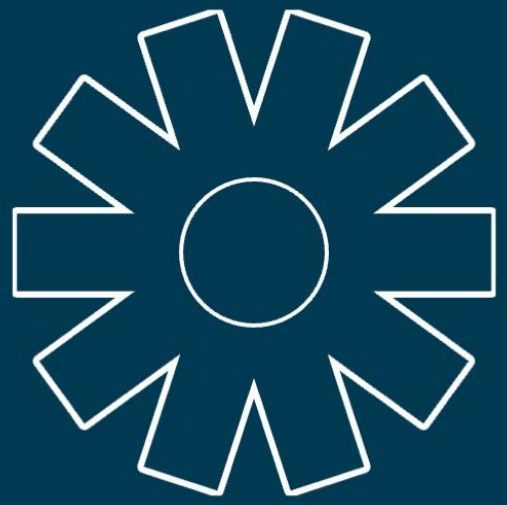

downloadOnePdf()
finally

KODE

```python
# ---What the script runs:
if __name__ == "__main__":
    print("...")
    listHandling()
    print('...')
    createDir()
    print('...')
    downloadAllPDFS()
    print('...')
    createReport()
    print('The program is done!...')


# ---Space for test functions
testRow = ["",  "BrNr...", "link1...", "link2..."]
downloadOnePdf(testRow, 1)
print(testRow)
```

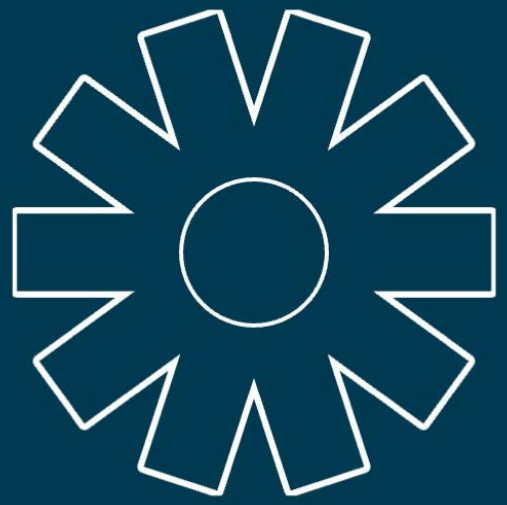

When run

RESULTAT OG LÆRING

- Det virker.
- Der er error messages i terminalen der fortæller hvorfor et link ikke blev downloadet.
- Der kan laves unit tests.
- Hvis scriptet bliver afbrudt kommer der ikke en rapport.
- Så langsomt det næsten er ubrugeligt.

RESULTAT OG LÆRING

- Det virker.
- Der er error messages i terminalen der fortæller hvorfor et link ikke blev downloadet.
- Der kan laves unit tests.
- Hvis scriptet bliver afbrudt kommer der ikke en rapport.
- Så langsomt det næsten er ubrugeligt.

- Jeg ku ha brugt `concurrent.futures` for at gøre scriptet hurtigere.
- Jeg burde ha isoleret stederne i koden der skulle ændres, til toppen af scriptet, for brugervenlighed.
- Brugt `pypdf` som filechecker.
- Checke for og benytte allerede installerede filer. Ikke lave ny folder.
- Opsætte bedre testrammer for projektet via bl.a. pytest

TEST AF LUNAS SCRIPT

- Håndtere kolonne AM link
  - Virker men kommer med en random fejl
- Tilføjede 'tællere' for logging:
  - Fil downloadet fra link 1
  - Fil downloadet fra link 2
  - Fil eksistere allrede
  - Link 1 havde en fejl, ingen link 2
  - Link 1 og link 2 havde begge fejl
- Tilføjede `if __name__ == "__main__":` så scriptet nemmere kan unit testes

TEST AF LUNAS SCRIPT

- Håndtere kolonne AM link
  - Virker men kommer med en random fejl
- Tilføjede 'tællere' for logging:
  - Fil downloadet fra link 1
  - Fil downloadet fra link 2
  - Fil eksistere allrede
  - Link 1 havde en fejl, ingen link 2
  - Link 1 og link 2 havde begge fejl
- Tilføjede `if __name__ == "__main__":` så scriptet nemmere kan unit testes
- Gjorde tilføjede raise statements til hendes try, except
- Sendte Luna:
  - Min kode via github forket.
  - Feedback og Testrapport
    - Små forbedringer
    - Relevante forbedringer
    - Testing

TAK